Implementación de un proceso de limpieza y estandarización de datos de morbilidad basado en CIE-10 en el Hospital Susana López de Valencia

Autores: Rodrigo Andres Realpe Chilito, Luis Fernando Vivas Fernandez

Director: Oscar Andres Angulo Lopez

Programa: Ingeniería de Sistemas

Universidad: Corporación Universitaria Comfacauca - Unicomfacauca

Popayán, Colombia

2026

Índice

1. Introducción y Planteamiento del Problema **2**

1.1. Introducción 2

1.2. Pregunta de Investigación 3

1.3. Planteamiento del Problema 3

1.4. Justificación 4

1.5. Objetivos 6

1.5.1. Objetivo General 6

1.5.2. Objetivos Específicos 6

1.6. Alcance y Limitaciones 6

1.6.1. Alcance 6

1.6.2. Limitaciones del alcance 7

2. Marco Teórico **8**

2.1. Antecedentes de la Investigación 8

2.2. Estado del Arte 8

2.3. Fundamentación Teórica 8

3. Análisis del Problema **9**

3.1. Análisis del Problema 9

3.2. Árbol de Problemas 10

3.3. Árbol de Objetivos 11

4. Metodología **12**

4.1. Tipo de investigación 12

4.2. Enfoque de la investigación 12

4.3. Métodos y técnicas de recolección de datos 12

4.4. Procedimiento metodológico 13

4.5. Técnicas de análisis de datos 13
4.6. Herramientas y recursos 14
4.7. Consideraciones éticas 14
4.8. Validez y confiabilidad 15

5. Plan de Trabajo y Cronograma **16**

6. Resultados Esperados e Impacto **17**
6.1. Productos o Entregables Esperados 17
6.2. Beneficios para la Institución, Comunidad o Industria 17

7. Cronograma de Implementación **18**

8. Referencias Bibliográficas **19**

Anexos **20**

Resumen

Escribe aquí tu resumen ejecutivo. Debe tener entre 150 y 250 palabras y cubrir: el problema que aborda el proyecto, el objetivo general, la metodología empleada y los resultados que se esperan obtener.

Palabras clave: *Aquí van las palabras clave, separdas por comas*

1. Introducción y Planteamiento del Problema

1.1. Introducción

La calidad de los datos utilizados en el sector salud se ha convertido en un factor fundamental para la toma de decisiones clínicas, ya que estos provienen de datos del mundo real (RWD, *Real World Data*), los cuales son recopilados mediante herramientas como los registros electrónicos de salud (EHRs, *Electronic Health Records*). A partir de estos registros se genera la evidencia del mundo real (RWE, *Real World Evidence*), la cual constituye una base esencial para la toma de decisiones dentro de las instituciones clínicas (Lighterness et al., 2024).

Pese a esto, Ben et al. (2024) señala que las fuentes de datos del mundo real suelen presentar inconsistencias y problemas de calidad, tales como valores atípicos, valores faltantes, errores de formato e incoherencias semánticas. Estas deficiencias comprometen la utilidad y confiabilidad de los datos para su análisis y, por ende, su posterior uso en la toma de decisiones.

En este contexto, el procesamiento y la limpieza de los datos clínicos se convierten en etapas fundamentales dentro de las instituciones de salud. Los errores en las fases de preparación y limpieza afectan directamente los resultados derivados de estos datos, lo que resalta la necesidad de comprender y estructurar adecuadamente dichos procesos (Albu et al., 2025).

En el caso del Hospital Susana López de Valencia, en el area de epidemiología, el proceso de análisis de morbilidad se basa en la extracción y limpieza de datos provenientes de registros clínicos institucionales (*Procedimiento de Morbilidad Institucional*, s.f.). Actualmente, este proceso es realizado de manera manual, lo que implica la aplicación de criterios no estandarizados y la ausencia de mecanismos formales de trazabilidad y validación. Esta situación puede generar pérdida de información relevante, inconsistencias en los resultados y limitaciones en la confiabilidad de los análisis realizados.

1.2. Pregunta de Investigación

¿Cómo implementar un proceso de limpieza de datos que garantice la trazabilidad, estandarización y confiabilidad de la información de morbilidad en el área de epidemiología del Hospital Susana López de Valencia?

1.3. Planteamiento del Problema

La calidad de los datos en el sector salud constituye un elemento fundamental para la toma de decisiones clínicas, dado que estos provienen de datos del mundo real (RWD) recopilados mediante registros electrónicos de salud (EHR), a partir de los cuales se genera evidencia del mundo real (RWE), utilizada en procesos clínicos y epidemiológicos (Lighterness et al., 2024).

No obstante, diversos estudios han evidenciado que las fuentes de datos clínicos presentan inconsistencias y problemas de calidad, tales como valores faltantes, errores de formato, valores atípicos e incoherencias semánticas, lo cual compromete su utilidad y confiabilidad para el análisis Ben et al. (2024). Estas deficiencias impactan directamente los resultados obtenidos a partir de dichos datos, afectando procesos posteriores como el análisis epidemiológico y la toma de decisiones.

En este sentido, el procesamiento y la limpieza de los datos clínicos se convierten en etapas críticas dentro de los sistemas de información en salud. Errores en estas fases pueden propagarse a lo largo del análisis, generando resultados inconsistentes o poco confiables, lo que resalta la necesidad de estructurar adecuadamente dichos procesos (Albu et al., 2025). Además, la integración y manejo de datos en entornos clínicos es un proceso complejo que involucra múltiples fuentes y estructuras, lo que incrementa la probabilidad de inconsistencias si no existen mecanismos adecuados de control (Petri et al., 2025).

En el contexto del Hospital Susana López de Valencia, el análisis de morbilidad se realiza a partir de datos provenientes del sistema institucional, los cuales son sometidos a un proceso de limpieza previo al análisis. Sin embargo, este proceso se ejecuta de manera manual, sin la existencia de criterios estandarizados ni mecanismos formales de trazabilidad que permitan documentar las

decisiones tomadas durante la depuración de los datos (*Procedimiento de Morbilidad Institucional*, s.f.).

Adicionalmente, el levantamiento de requerimientos evidencia que la limpieza de datos presenta inconsistencias en la aplicación de criterios, así como la eliminación de información potencialmente relevante, especialmente en diagnósticos secundarios, lo cual puede afectar la representatividad de los datos analizados (*Especificación de Requerimientos de Datos (SRS/DRS) para la Plataforma de Análisis de Morbilidad Institucional*, 2026). Esta situación se ve agravada por la ausencia de mecanismos de validación que permitan verificar la calidad y consistencia de los resultados obtenidos, dificultando la reproducibilidad del proceso y la confiabilidad de los análisis generados.

En consecuencia, la falta de organización, trazabilidad, estandarización y validación en el proceso de limpieza de datos de morbilidad limita la calidad de la información disponible para el análisis epidemiológico en la institución, lo que puede repercutir en la toma de decisiones basada en dichos datos.

1.4. Justificación

La calidad de los datos en el sector salud representa un factor determinante en la generación de información confiable para la toma de decisiones clínicas y administrativas. En este contexto, los datos provenientes de registros electrónicos de salud constituyen una fuente principal para el análisis de fenómenos como la morbilidad, los cuales permiten comprender el comportamiento de enfermedades dentro de una población. Sin embargo, diversos estudios han evidenciado que los datos del mundo real suelen presentar problemas de calidad, tales como inconsistencias, valores faltantes, errores de formato e incoherencias semánticas, lo cual compromete su utilidad para el análisis y la toma de decisiones (Ben et al., 2024; Lighterness et al., 2024).

Adicionalmente, el procesamiento y la preparación de estos datos representan etapas críticas dentro de los flujos de análisis en salud, ya que los errores introducidos en estas fases afectan directamente los resultados posteriores. La literatura resalta la necesidad de estructurar adecuada-

mente estos procesos, dado que la falta de control, estandarización y validación puede derivar en resultados inconsistentes o poco confiables (Albu et al., 2025; Petri et al., 2025). Asimismo, se ha identificado que la ausencia de procesos formales para evaluar la calidad de los datos dificulta determinar si estos son adecuados para su uso en investigación o análisis clínico, lo que evidencia la necesidad de implementar mecanismos de control y validación (Blacketer et al., 2021).

En el contexto del Hospital Susana López de Valencia, el proceso de análisis de morbilidad se basa en la limpieza y depuración de datos provenientes de registros clínicos institucionales. Actualmente, este proceso se realiza de manera manual, lo que implica la aplicación de criterios no estandarizados y la ausencia de mecanismos formales de trazabilidad y validación. Esta situación puede generar pérdida de información relevante, inconsistencias en los resultados y limitaciones en la confiabilidad de los análisis, afectando potencialmente la calidad de la información utilizada para la toma de decisiones dentro de la institución.

En este sentido, se hace necesaria la implementación de un proceso estructurado que permita organizar, estandarizar y garantizar la trazabilidad en la limpieza de datos de morbilidad, así como incorporar mecanismos de validación que aseguren la calidad y confiabilidad de la información generada. La adopción de este tipo de enfoques no solo contribuye a mejorar la consistencia de los resultados, sino que también permite fortalecer la reproducibilidad de los análisis y la transparencia en el manejo de los datos.

Por tanto, el presente proyecto se justifica en la necesidad de abordar un problema real dentro del contexto hospitalario, mediante la aplicación de estrategias que permitan mejorar el proceso de limpieza de datos de morbilidad, contribuyendo así a la generación de información más confiable para el análisis epidemiológico y la toma de decisiones en el Hospital Susana López de Valencia.

1.5. Objetivos

1.5.1. Objetivo General

Implementar un proceso de limpieza de datos que garantice la trazabilidad, estandarización y confiabilidad de la información de morbilidad en el área de epidemiología del Hospital Susana López de Valencia.

1.5.2. Objetivos Específicos

1. Diseñar un proceso de trazabilidad y documentación que permita registrar las decisiones tomadas durante la limpieza de datos de morbilidad.

2. Definir criterios técnicos y estandarizados para la selección y limpieza de los datos de morbilidad provenientes del sistema institucional.

3. Implementar mecanismos de validación que permitan evaluar la calidad, consistencia y confiabilidad de los datos procesados.

1.6. Alcance y Limitaciones

1.6.1. Alcance

El presente proyecto contempla la implementación de un proceso estructurado para la limpieza de datos de morbilidad en el área de epidemiología del Hospital Susana López de Valencia. Este proceso incluye el análisis exploratorio y perfilamiento de los datos, con el fin de comprender su estructura, identificar problemas de calidad y definir criterios adecuados para su tratamiento.

Asimismo, el proyecto abarca la definición de reglas de limpieza, la incorporación de mecanismos de trazabilidad que permitan registrar las decisiones tomadas durante el proceso, y la implementación de procedimientos de validación orientados a evaluar la calidad, consistencia y confiabilidad de los datos procesados.

El proceso será implementado mediante herramientas de análisis de datos y diseñado de tal

forma que pueda ser ejecutado y utilizado por el personal encargado del proceso actual, permitiendo su aplicación práctica sobre los datos institucionales.

El proceso será aplicado sobre datos reales proporcionados por la institución, correspondientes a registros de pacientes en el periodo comprendido entre enero y marzo del 2025, lo que permitirá evaluar su funcionamiento en un contexto real y contrastarlo con el método actual de limpieza manual.

1.6.2. Limitaciones del alcance

El proceso implementado no contempla su integración directa con los sistemas institucionales del hospital, por lo que su ejecución se realizará de manera independiente al flujo operativo actual.

El acceso y uso de los datos estará sujeto a las condiciones establecidas por la institución, garantizando en todo momento la confidencialidad de la información y el uso exclusivo con fines académicos, evitando la exposición o uso indebido de datos personales sensibles.

Finalmente, el proceso será evaluado sobre un conjunto específico de datos correspondiente a un periodo determinado, por lo que su comportamiento frente a otros conjuntos de datos deberá analizarse en futuros trabajos.

2. Marco Teórico

2.1. Antecedentes de la Investigación

Presenta investigaciones o proyectos previos relevantes para tu tema.

2.2. Estado del Arte

Describe el nivel de avance actual del conocimiento sobre el problema que abordas (**autor2022**).

2.3. Fundamentación Teórica

Define y desarrolla los conceptos clave que sustentan el proyecto.

3. Análisis del Problema

3.1. Análisis del Problema

El proceso de limpieza de datos de morbilidad en el área de epidemiología del Hospital Susana López de Valencia presenta deficiencias relacionadas con la falta de organización, trazabilidad y estandarización. Estas deficiencias afectan la calidad de la información utilizada para el análisis epidemiológico y la toma de decisiones dentro de la institución.

En primer lugar, se identifica la ausencia de mecanismos de trazabilidad que permitan registrar y documentar las decisiones tomadas durante el proceso de limpieza de datos. Esto impide conocer el origen de las modificaciones realizadas, dificultando la auditoría y reproducibilidad del proceso.

En segundo lugar, la aplicación de criterios de limpieza no estandarizados genera inconsistencias en el tratamiento de los datos. La falta de lineamientos técnicos claros puede derivar en la eliminación de información relevante, particularmente en diagnósticos secundarios, afectando la representatividad de los datos analizados.

Adicionalmente, se evidencia la ausencia de mecanismos de validación que permitan verificar la calidad y consistencia de los resultados obtenidos. Esto limita la confiabilidad del proceso, ya que no existen procedimientos formales para evaluar si los datos procesados cumplen con condiciones adecuadas para su análisis.

Como consecuencia de estas problemáticas, se generan efectos negativos como la pérdida de información relevante, inconsistencias en los resultados y limitaciones en la confiabilidad de los análisis epidemiológicos. En conjunto, estos factores pueden impactar la calidad de la información utilizada para la toma de decisiones dentro de la institución.

Por lo tanto, se hace necesario estructurar un proceso de limpieza de datos que incorpore mecanismos de trazabilidad, estandarización y validación, con el fin de mejorar la calidad y confiabilidad de la información de morbilidad.

3.2. Árbol de Problemas

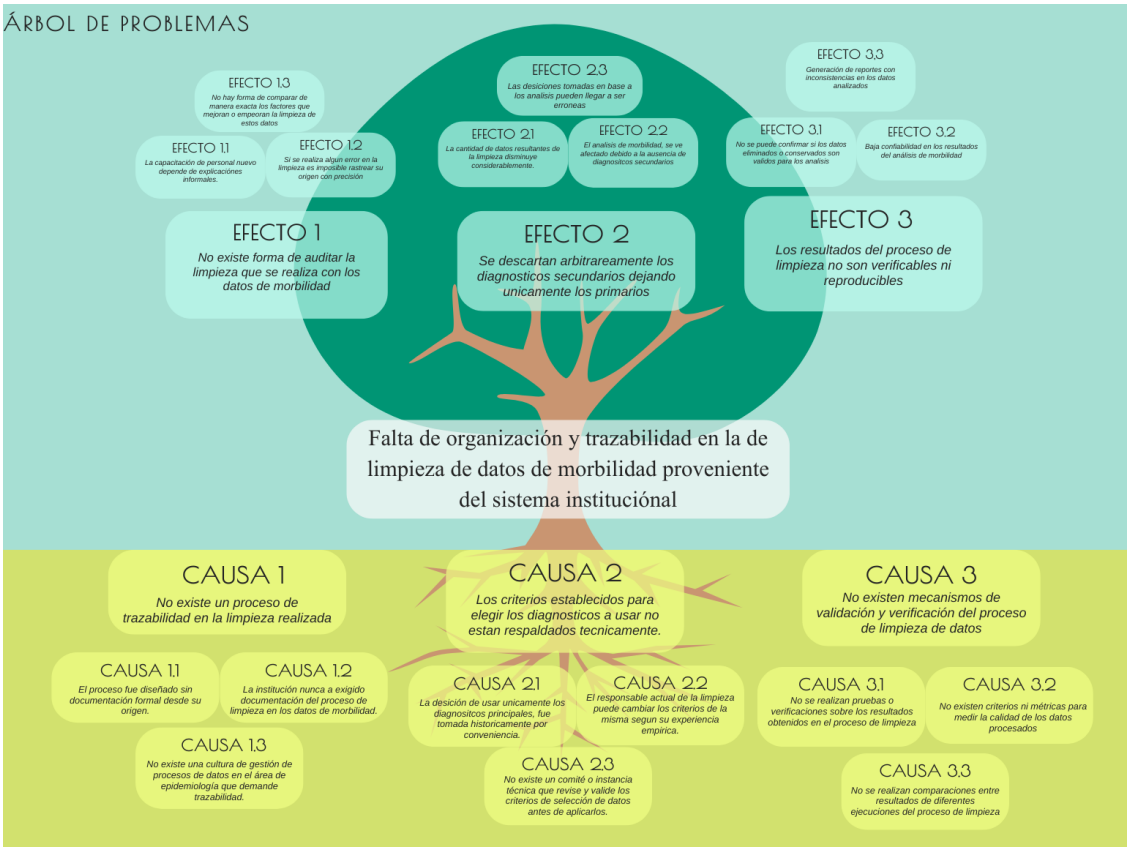

Figura 1
Nota. Árbol de problemas del proceso de limpieza de datos de morbilidad en el área de epidemiología del Hospital Susana López de Valencia.

3.3. Árbol de Objetivos

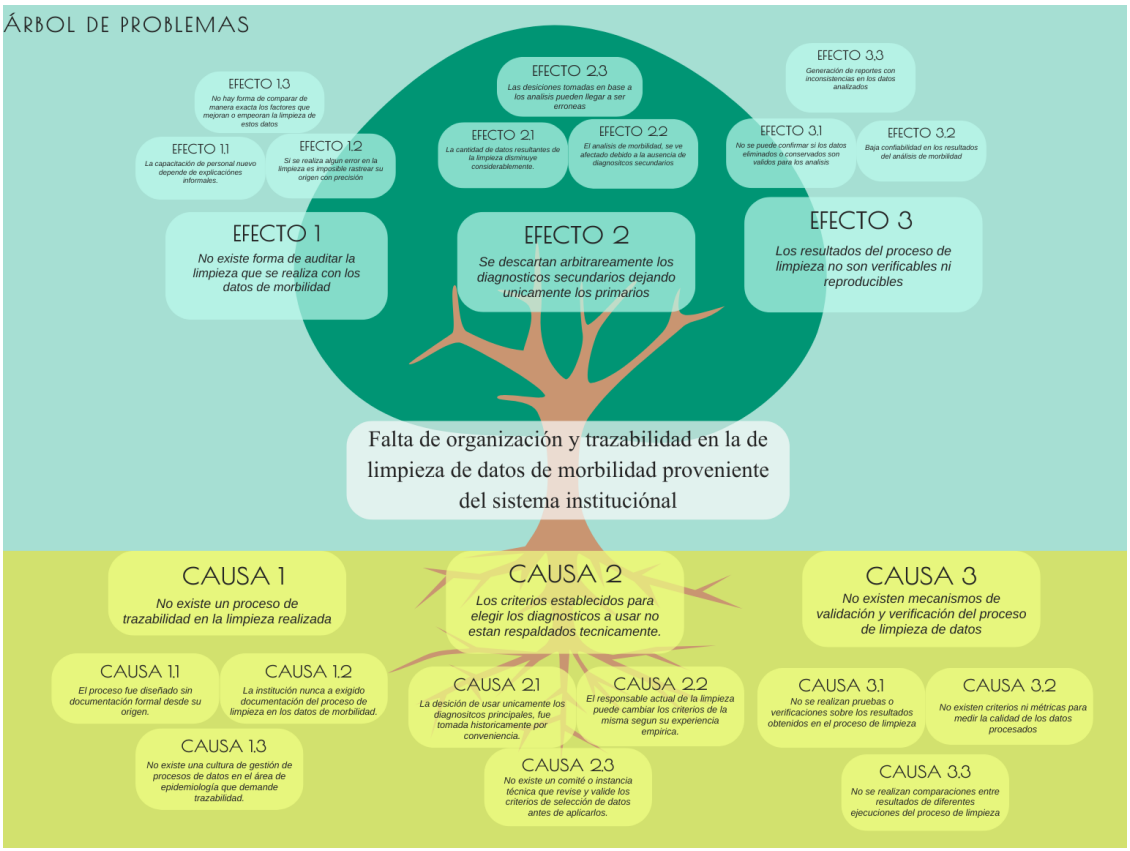

Figura 2
Nota. Árbol de objetivos del proceso de limpieza de datos de morbilidad en el área de epidemiología del Hospital Susana López de Valencia.

4. Metodología

4.1. Tipo de investigación

El presente proyecto se enmarca en una investigación aplicada, orientada a la solución de un problema real dentro del contexto del Hospital Susana López de Valencia. Específicamente, corresponde a un proyecto de desarrollo tecnológico, dado que propone la implementación de un proceso estructurado para la limpieza de datos de morbilidad.

Adicionalmente, el proyecto incorpora un componente de validación empírica, al evaluar el comportamiento del proceso propuesto sobre datos reales y compararlo con el método actual de limpieza manual.

4.2. Enfoque de la investigación

La investigación adopta un enfoque cuantitativo, debido a que se basa en el análisis de datos clínicos estructurados, la aplicación de reglas de limpieza y la evaluación de resultados mediante métricas de calidad de datos.

Este enfoque permite medir la consistencia, completitud y confiabilidad de los datos antes y después de aplicar el proceso propuesto.

4.3. Métodos y técnicas de recolección de datos

Los datos utilizados en el proyecto serán proporcionados por el Hospital Susana López de Valencia, correspondientes a registros de morbilidad en formato Excel, que contienen diagnósticos codificados bajo la clasificación CIE-10.

La recolección de datos se realizará mediante el acceso a estos archivos institucionales, los cuales representan el insumo principal para el desarrollo del proceso de limpieza.

No se contemplan técnicas de recolección como encuestas o entrevistas, ya que el enfoque del proyecto es técnico y centrado en el procesamiento de datos existentes.

4.4. Procedimiento metodológico

El desarrollo del proyecto se llevará a cabo mediante un proceso estructurado de limpieza de datos, compuesto por las siguientes etapas:

1. **Recolección de datos:** Obtención de los archivos de morbilidad en formato Excel proporcionados por la institución, correspondientes al periodo de estudio definido.

2. **Perfilamiento de datos:** Análisis exploratorio de los datos (data profiling) para identificar su estructura, tipos de variables, valores faltantes, inconsistencias, duplicados y patrones relevantes.

3. **Definición de criterios de limpieza:** Establecimiento de reglas técnicas para el tratamiento de los datos, incluyendo criterios para selección de diagnósticos, manejo de valores nulos, normalización de formatos y validación de códigos CIE-10.

4. **Implementación del proceso de limpieza:** Aplicación de las reglas definidas mediante herramientas de análisis de datos, transformando los datos originales en un conjunto estructurado y consistente.

5. **Trazabilidad del proceso:** Registro de las decisiones tomadas durante la limpieza de datos, permitiendo documentar los criterios aplicados y facilitar la reproducibilidad del proceso.

6. **Validación de resultados:** Evaluación de la calidad de los datos procesados mediante la verificación de consistencia, comparación con el proceso manual y análisis de diferencias en los resultados obtenidos.

4.5. Técnicas de análisis de datos

El análisis del proceso propuesto se centrará en la evaluación de su consistencia, trazabilidad y reproducibilidad, más que en la corrección de errores en los datos.

En este sentido, se analizarán los siguientes aspectos:

- Reproducibilidad del proceso, verificando que la aplicación de las mismas reglas genere resultados consistentes en diferentes ejecuciones.
- Trazabilidad de las decisiones, asegurando que cada transformación aplicada a los datos pueda ser identificada y justificada.
- Consistencia del proceso frente al método manual actual, evaluando si los resultados dependen de criterios definidos y no de decisiones individuales.
- Comparación de resultados con el proceso manual, identificando diferencias en la selección y tratamiento de los datos.

Estos elementos permitirán determinar si el proceso propuesto mejora la confiabilidad y transparencia en la limpieza de los datos de morbilidad.

4.6. Herramientas y recursos

El desarrollo del proyecto se apoyará en herramientas de análisis de datos, específicamente:

- Lenguaje de programación Python
- Entorno de desarrollo Jupyter Notebook
- Librerías de procesamiento de datos como Pandas y NumPy

Estas herramientas permitirán implementar un flujo reproducible de procesamiento, facilitando la ejecución, documentación y validación del proceso de limpieza.

4.7. Consideraciones éticas

El proyecto se desarrollará utilizando datos reales proporcionados por la institución, por lo que se garantizará en todo momento la confidencialidad de la información.

Los datos serán utilizados exclusivamente con fines académicos, evitando la exposición de información sensible o identificable de los pacientes. En caso de ser necesario, se aplicarán procesos de anonimización para proteger la identidad de los individuos.

Asimismo, el acceso a los datos estará sujeto a las condiciones establecidas por el hospital, asegurando el cumplimiento de las políticas institucionales y normativas relacionadas con el manejo de información en el sector salud.

4.8. Validez y confiabilidad

La validez del proceso se garantizará mediante la correcta definición de criterios de limpieza basados en el análisis de los datos y en el contexto institucional.

La confiabilidad se asegurará a través de la reproducibilidad del proceso, permitiendo aplicar las mismas reglas sobre distintos conjuntos de datos y obtener resultados consistentes.

Adicionalmente, la comparación con el proceso manual actual permitirá evaluar la coherencia y utilidad de los resultados obtenidos.

5. Plan de Trabajo y Cronograma

Describe las fases y actividades del proyecto. Puedes insertar aquí una tabla o diagrama de Gantt como figura (ver instrucciones en el Capítulo 3 para insertar imágenes).

[Inserta aquí la tabla de actividades con fechas y responsables]

6. Resultados Esperados e Impacto

6.1. Productos o Entregables Esperados

- Primer entregable esperado.
- Segundo entregable esperado.

6.2. Beneficios para la Institución, Comunidad o Industria

Describe el impacto positivo que tendrá el proyecto al concluirse.

7. Cronograma de Implementación

[Inserta aquí el diagrama de Gantt u otra representación gráfica]

8. Referencias Bibliográficas

Albu, E., Gao, S., Stijnen, P., Rademakers, F. E., Van Bussel, B. C., Collyer, T., Hernandez-Boussard, T., Wynants, L., & Van Calster, B. (2025). Challenges and Recommendations for Electronic Health Records Data Extraction and Preparation for Dynamic Prediction Modeling in Hospitalized Patients: Practical Guide and Tutorial. *Journal of Medical Internet Research*, *27*, e73987. https://doi.org/10.2196/73987

Ben, T., Adebayo, H., & Jeremiah, O. (2024). A Scalable Data Quality Assessment and Automated Cleaning Framework for Large-Scale Healthcare Databases Using Python-Based Machine Learning and Rule-Driven Validation Techniques.

Blacketer, C., Voss, E. A., DeFalco, F., Hughes, N., Schuemie, M. J., Moinat, M., & Rijnbeek, P. R. (2021). Using the Data Quality Dashboard to Improve the EHDEN Network. *Applied Sciences*, *11*(24), 11920. https://doi.org/10.3390/app112411920

Especificación de Requerimientos de Datos (SRS/DRS) para la Plataforma de Análisis de Morbilidad Institucional (Documento técnico de levantamiento de requerimientos). (2026) (Basado en el estándar ISO/IEC/IEEE 29148:2018). Hospital Susana López de Valencia. Popayán, Colombia.

Lighterness, A., Adcock, M., Scanlon, L. A., & Price, G. (2024). Data Quality–Driven Improvement in Health Care: Systematic Literature Review. *Journal of Medical Internet Research*, *26*, e57615. https://doi.org/10.2196/57615

Petri, V., Antoine, T., Emma, B., Hervé, H., Emma, F., & Hana, V. (2025). Clinical data integration and processing challenges in healthcare caused by contemporary software design. *DIGITAL HEALTH*, *11*, 20552076251374233. https://doi.org/10.1177/20552076251374233

Procedimiento de Morbilidad Institucional [Código: SLV-GC-01, Documento institucional de gestión clínica y epidemiológica]. (s.f.). Hospital Susana López de Valencia E.S.E. Popayán, Colombia.

Anexos

Anexo A – Nombre del Primer Anexo

Descripción o contenido del primer anexo.

Anexo B – Nombre del Segundo Anexo

Descripción o contenido del segundo anexo.