Idea de Anteproyecto

Rodrigo Andres Realpe Chilito

Luis Fernando Vivas Fernandez

Corporación Universitaria Comfacauca - Unicomfacauca

Docente: Oscar Andres Angulo Lopez

Marzo 2026

Posible título

Diseñar e implementar un pipeline y un esquema de datos estandarizado para integrar y diferenciar diagnósticos principales y secundarios en la morbilidad del Hospital Susana López de Valencia, mediante limpieza y clasificación.

Contexto del problema

El Hospital Susana López de Valencia mensualmente recolecta y analiza datos que contienen los diagnósticos principales de los pacientes en las diferentes áreas. Estos datos se recopilan, almacenan, analizan y se presentan de acuerdo con los lineamientos vigentes **Big Data SLV-SI-47 versión 0** y **Minería de Datos SLV-SI-16 versión 2** de la institución. Esto se genera mensualmente para monitorear el comportamiento de los diagnósticos en las diferentes áreas del hospital (urgencias, hospitalización, consulta ambulatoria, especialidades médicas, etc.). Los reportes son generados a partir de los datos almacenados en el sistema institucional de información, llamado **Dinámica Gerencial**. Los análisis de estas reuniones mensuales no solo son fundamentales para la toma de decisiones del hospital. También son usados para la elaboración del perfil epidemiológico anual.

Se sabe que la base de datos que recoge los diferentes diagnósticos de cada área llega a tener entre **160.000-200.000** diagnósticos. Además, cada paciente puede tener hasta 10 diagnósticos secundarios. Sin embargo, los diagnósticos secundarios se desechan, dejando únicamente los primarios y reduciendo la cantidad de datos a **8.000-10.000**, teniendo en cuenta que los folios 64 y 64W sí o sí deben ser desechados. Esto reduce en una gran cantidad los datos de los diagnósticos que serán analizados y afecta significativamente la calidad de los reportes y, por consecuencia, la toma de decisiones con respecto a la morbilidad del hospital.

Justificación

El procedimiento vigente en el **Hospital Susana López de Valencia** establece lineamientos para recolectar, depurar y clasificar diagnósticos según la *CIE-10*. Sin embargo, dicho procedimiento presenta una limitación importante: elimina sistemáticamente los diagnósticos secundarios, conservando únicamente el diagnóstico principal, aun cuando un paciente puede tener hasta diez secundarios en un mes. Esto impide capturar la totalidad de los patrones relevantes de la población atendida.

La institución planea realizar un perfilamiento epidemiológico avanzado, lo que requiere una base de datos limpia, completa y estructurada que incluya todos los diagnósticos. Este proyecto provee exactamente ese insumo mediante un proceso automatizado.

Actualmente, el proceso depende de un solo profesional, requiere entre dos y tres días de ejecución manual y carece de trazabilidad sistemática, lo que limita su auditoría, reproducibilidad y escalabilidad futura.[1]

El proyecto se justifica por tres razones: en la dimensión institucional, porque permite estandarizar la limpieza de datos y conservar los diagnósticos secundarios; en la dimensión técnica, porque automatiza el proceso mediante *Python*, aumentando eficiencia, trazabilidad y reproducibilidad; y en la dimensión académica, porque aplica conocimientos de ingeniería de sistemas en un contexto real, generando un producto tangible y medible.

Problema concreto

Qué falla: La limpieza que se realiza de los datos usados para el análisis y la posterior creación de reportes se reduce a *8.000-10.000* filas debido a que el método de limpieza vigente desecha todos los diagnósticos secundarios. Se estima que cada paciente puede llegar a tener hasta **10 diagnósticos** secundarios.

[1] La fuente de este dato, se valido por ausencia de lo mencionado en los pasos registrados en el documento ”PROCEDIMIENTO MORBILIDAD”proporcionado por el hospital

Dónde ocurre: Este problema ocurre en la limpieza de datos. Se desechan los datos secundarios reduciendo de manera considerable los datos de que se analizan para el informe de morbilidad.

Consecuencia: Al momento de analizar los datos en las reuniones como comités, la calidad de dichos datos y la falta de los datos secundarios presenta un vacío importante para los siguientes aspectos: análisis carente de los diagnósticos secundarios, falta de calidad en el monitoreo del comportamiento de morbilidad, falta de información para identificar patrones o comportamientos de calidad y toma de decisiones afectada por los anteriores puntos.

Pregunta de investigación

¿Cómo diseñar e implementar un pipeline y esquema de datos estandarizado para integrar todos los diagnósticos en los registros de morbilidad del hospital Susana Lopez de Valencia bajo la clasificación CIE-10?

Objetivos

Objetivo general:

Diseñar e implementar un pipeline de limpieza y un esquema de datos estandarizado para la integración y diferenciación de diagnósticos principales y secundarios en las bases de datos de morbilidad del Hospital Susana López de Valencia, mediante criterios documentados y trazables alineados con la taxonomía institucional CIE-10 de grandes causas y subcausas clínicas, que mejore la calidad y completitud de la información disponible para el análisis epidemiológico institucional.

Objetivos específicos:

- Caracterizar la estructura actual de las bases de datos de morbilidad institucional correspondientes al primer trimestre de 2025 mediante un análisis exploratorio que identifique varia-

bles, tipos de datos, inconsistencias, valores atípicos, y el estado de registro de diagnósticos principales y secundarios frente al conjunto mínimo de variables definido en el procedimiento institucional.

- Definir e implementar un pipeline de limpieza estandarizado y trazable en Python y Jupyter Notebook, aplicando criterios documentados que incluyan la eliminación de registros Folio 64 y Folio 64W, la depuración de duplicados por número de ingreso, el tratamiento de valores atípicos, la validación de códigos CIE-10, y la retención de diagnósticos secundarios, con registro sistemático de cada decisión en una bitácora.

- Diseñar e implementar un esquema de datos consolidado que integre diagnósticos principales y hasta diez diagnósticos secundarios por paciente, clasificados según la taxonomía institucional de grandes causas y subcausas clínicas CIE-10, y validarlo mediante métricas de calidad que evidencien mejoras en completitud, consistencia y validez frente al estado inicial.

Idea central

Hacer el diseño y la implementación de un esquema y un pipeline que estandarice el proceso de filtrado de datos y sus resultados, con el fin de que se contemplen todos los diagnósticos, no solo los principales, y ayude a mejorar de manera considerable los análisis y reportes generados en base a estos. Ayudando de manera retroactiva los futuros procesos del hospital que necesiten datos limpios y completos

Variables / métricas

- Métrica 1: Total de filas recibidas por mes.

- Métrica 2: Número y porcentaje de registros con diagnóstico principal vacío o inválido.

- Métrica 3: Número y porcentaje de registros con diagnósticos secundarios presentes y ausentes.
- Métrica 4: Promedio de diagnósticos secundarios por paciente.
- Métrica 5: Número de registros identificados como Folio 64 y Folio 64W.
- Métrica 6: Variables con valores atípicos detectados (por ejemplo, edades fuera de rango lógico).
- Métrica 7: Porcentaje de completitud por variable obligatoria (diagnóstico, edad, sexo, servicio de atención).
- Métrica 8: Filas eliminadas por cada criterio aplicado, con porcentaje.
- Métrica 9: Filas eliminadas específicamente por Folio 64 y Folio 64W.
- Métrica 10: Filas con códigos CIE-10 inválidos corregidos o eliminados, con justificación.
- Métrica 11: Filas con valores atípicos tratados y criterio aplicado.
- Métrica 12: Diagnósticos secundarios retenidos vs eliminados según proceso habitual.
- Métrica 13: Tiempo de ejecución del pipeline automatizado.
- Métrica 14: Porcentaje de completitud del esquema final por variable obligatoria.
- Métrica 15: Número de pacientes con al menos un diagnóstico secundario integrado.
- Métrica 16: Distribución de diagnósticos por grandes causas de morbilidad (principales vs principales más secundarios).
- Métrica 17: Porcentaje de registros válidos según reglas de calidad RC01 a RC06 antes y después del proceso.
- Métrica 18: Proporción de diagnósticos principales vs secundarios en el esquema final.

Restricciones

- Acceso: El equipo no tiene acceso directo a la base de datos del hospital. Los datos son proporcionados mensualmente por el área de Sistemas mediante una copia cargada en un servidor habilitado para consultas.
- Tiempo: Los datos se reciben una vez al mes, lo que limita la posibilidad de realizar aclaraciones o consultas adicionales sobre periodos específicos.
- Alcance: El proyecto se centra exclusivamente en la fase de preparación y estructuración de datos, sin realizar análisis clínicos ni conclusiones epidemiológicas.
- Datos disponibles: Solo se dispone de información correspondiente a enero, febrero y marzo de 2025, por lo que los resultados no pueden generalizarse a otros periodos sin validación adicional.
- Operación: El proceso de limpieza y estructuración depende de un único profesional cuya ejecución técnica no está documentada de forma replicable, lo que puede generar variaciones entre ciclos de ejecución.

Arbol de problemas

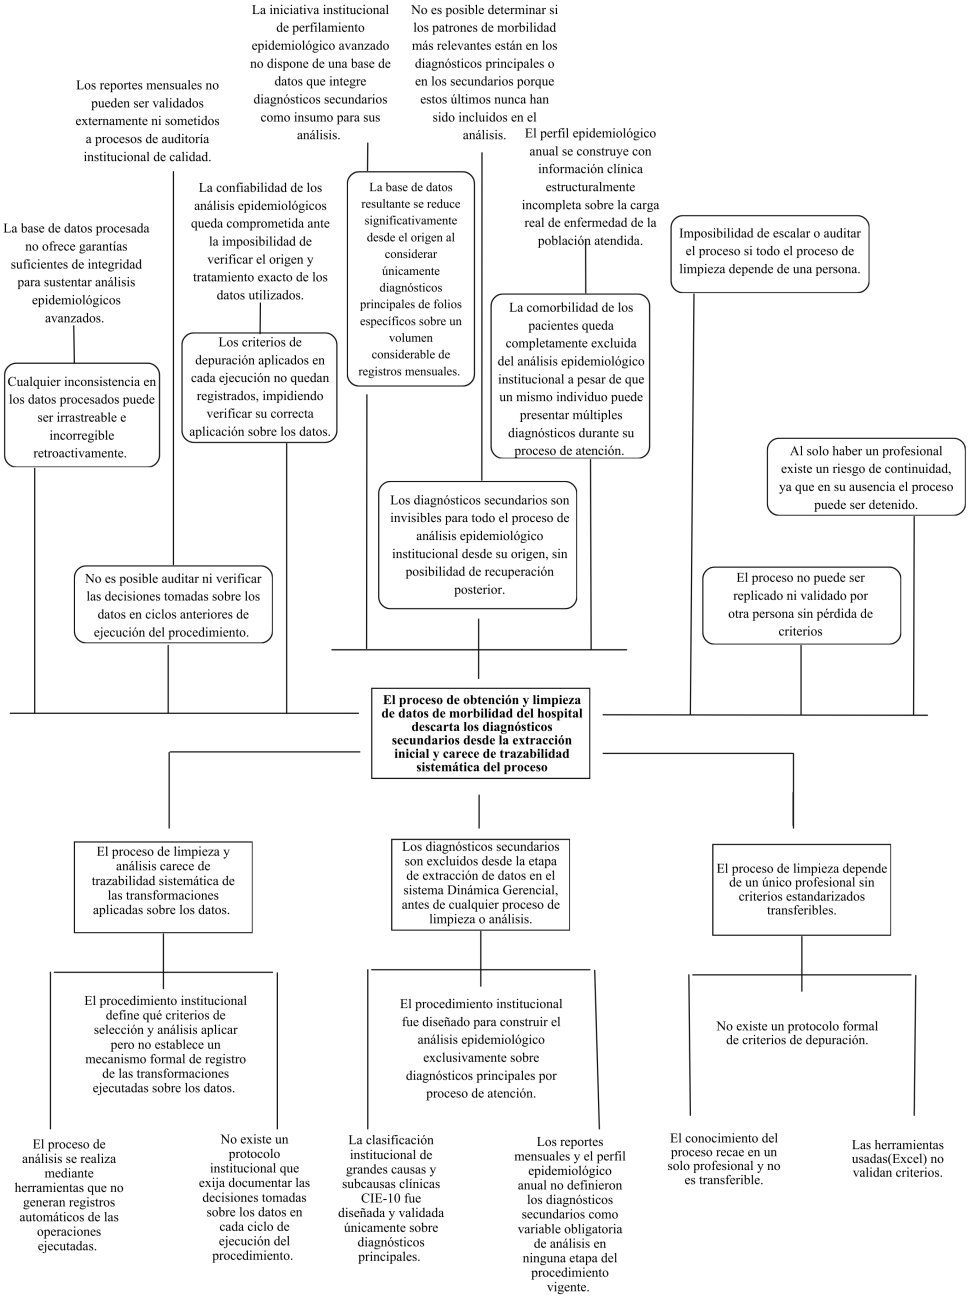

Figura 1: Árbol de problemas del Hospital Susana López de Valencia.